

REPORTE EJECUTIVO

Proyecto Final · Machine Learning con PySpark y Docker

Estudiante: Valentina Muñoz Palma

1. Resumen Ejecutivo

Este proyecto analiza dos conjuntos de datos colombianos usando PySpark y herramientas de Machine Learning. En los Bloques 1 y 2 se trabajó con el histórico de accidentalidad vial de Bogotá D.C. (199146 registros), con el objetivo de entender los patrones temporales y geográficos de los accidentes, identificar grupos de riesgo mediante agrupamiento, y predecir la gravedad del siniestro. Los resultados muestran que el tipo de accidente y la hora son los factores más importantes para predecir la gravedad. En el Bloque 3 se analizó el sentimiento de 11536 reseñas de hoteles en español, comparando un modelo construido con TF-IDF contra un modelo pre-entrenado de Hugging Face. Ambos modelos alcanzan resultados similares ($F1 = 0.8202$ y 0.8098), aunque el modelo pre-entrenado maneja mejor el lenguaje con negaciones y ambigüedad.

2. Metodología

Bloque 1 · Análisis Exploratorio con PySpark

Se cargó el dataset de accidentalidad vial de Bogotá con PySpark y se aplicaron transformaciones para extraer variables temporales (mes, día, hora, franja horaria). Se calculó estadística descriptiva y se detectó que las variables PK_CALZADA tiene un 19.07% de nulos, CIV tiene un 0.85% de nulos y LOCALIDAD tiene un 0.02% de nulos, mientras el resto del dataset está completo. Se construyeron visualizaciones de distribución por mes, hora, gravedad y localidad para identificar patrones de siniestralidad.

Bloque 2 · Machine Learning con Spark ML

Se construyó un pipeline de preparación con StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler. Se aplicó PCA (10 componentes, 40.96% de varianza explicada) y K-Means con $K=6$ elegido por el método del codo. Para la clasificación supervisada se entrenaron Regresión Logística y Random Forest sobre la variable GRAVEDAD, con balanceo por pesos (weightCol) para manejar el desbalance severo de la clase CON MUERTOS (general de 1.63%, train de 1.64% y test de 1.57%). Se compararon métricas y finalmente se validó el mejor modelo con CrossValidator.

Bloque 3 · NLP y modelo pre-entrenado

Se preparó un corpus de 11536 reseñas de hoteles en español eliminando 4815 duplicados (29.45%) y 4 reseñas en ruso. Se aplicó tokenización con RegexTokenizer con soporte para caracteres acentuados y filtrado de stop words en 6 idiomas para intentar eliminar palabras en idiomas que permanecieron luego del filtro que por porcentaje no justificaba un nuevo filtro para tratar de omitirlas. Se construyó un pipeline TF-IDF y se entrenó Regresión Logística para clasificar el sentimiento. Finalmente se comparó con el modelo pre-entrenado

pysentimiento/robertuito-sentiment-analysis de Hugging Face, probándolo con casos difíciles de sarcasmo, negaciones y ambigüedad.


3. Resultados Clave

Bloque 1 · Patrones de accidentalidad

La accidentalidad en Bogotá es sostenida durante todo el año, sin estacionalidad marcada, aunque Marzo presenta una cantidad de accidentados levemente mayor(18120).


Las localidades de Kennedy (23661 accidentes) y Engativá (20928) concentran la mayor siniestralidad.

El análisis por franja horaria muestra que la Hora Pico Mañana (6:00 – 9:00) tiene la mayor proporción de CON HERIDOS (37.20%) en comparación con Hora Valle (32.13%) y Hora Pico Tarde (35.07%), mientras que los atropellos son más frecuentes en la Hora Pico Tarde (12% vs 8.52% en la mañana y 9.8 en las horas valle), lo que indica mayor riesgo para peatones en horas de la tarde. Por otro lado podemos ver que en las tres franjas horarias predominan los choques y los accidentes con solo daños.




Bloque 2 · Agrupamiento y clasificación

El K-Means con K=6 identificó grupos con perfiles de riesgo muy distintos. El Clúster 5 es el más peligroso: está dominado por atropellos (no choques como los demás) y concentra el 78.5% de todos los accidentes con muertos del dataset. El Random Forest con validación cruzada (numTrees: 50 y maxDepth: 10) alcanzó un F1 ponderado de 0.6469 y accuracy de 0.6792. Las variables más importantes para predecir la gravedad fueron el tipo de accidente (CLASE_ACC, importancia acumulada: 0.656), seguido de la hora (0.083) y la latitud (0.059021).




La clase CON HERIDOS fue la más difícil de predecir, seguramente debido a la poca información de estos casos por el desbalanceo y la más fácil de predecir fue SOLO DAÑOS.



Bloque 3 · Análisis de sentimiento

El corpus posee un TTR de 0.0655 lo cual corresponde a una riqueza léxica baja esto es de esperarse ya que al ser un corpus de calificación de hoteles habrá un vocabulario muy similar entre documentos. De igual manera se encuentra que el 50.47% del vocabulario son Hapax legomena pero que dentro del corpus solo representa un 3.31%.

El modelo TF-IDF + Regresión Logística alcanzó un F1 ponderado de 0.8202 y accuracy de 0.8193. El modelo Hugging Face



(robertuito) obtuvo accuracy de 0.8288 pero un F1 de 0.8098. Las diferencias numéricas son pequeñas, pero cualitativamente Hugging Face maneja mejor las negaciones y la ambigüedad lingüística. Ninguno de los dos modelos detectó sarcasmo de forma confiable en las pruebas con casos difíciles. Pero en proporciones Hugging Face captura mejor las categorías minoritarias.

4. Reflexión Integradora

Los tres bloques cuentan una historia sobre dos problemas distintos, pero con una limitación común: los datos abiertos colombianos tienen valor analítico real, pero sus limitaciones informativas marcan el techo de lo que los modelos pueden lograr.

En accidentalidad vial, el EDA reveló que los patrones temporales y geográficos son claros y consistentes. El clustering nos confirmó carece de variables altamente representativas, factores que realmente determinan si un accidente deja heridos o muertos. Eso explica el F1 de 0.6469 y la alta confusión entre SOLO DAÑOS y CON HERIDOS.

En reseñas de hoteles, la situación fue diferente: el texto mismo contiene la información necesaria para predecir el sentimiento, lo que permitió alcanzar F1 de 0.8202 para TF-IDF y un F1 de 0.8098 para Hugging Face. La comparación entre TF-IDF y Hugging Face mostró que, para texto en español con lenguaje informal, un modelo pre-entrenado sobre millones de textos similares tiene ventajas en cuanto a capturar casos con menos información como los negativos y neutros, al mismo tiempo que maneja mejor las negaciones y ambigüedad de los documentos.

5. Limitaciones

- El dataset de accidentalidad no incluye variables de comportamiento del conductor, que podrían ser determinantes primarios de la gravedad real del accidente. Esto limita el F1 del modelo entre 0.6425 y 0.6469 sin importar qué modelo se use.
- La clase CON MUERTOS representa solo el 1.63% del dataset de accidentalidad. A pesar del balanceo por pesos (weightCol), el recall de esta clase sigue siendo bajo por la combinación de desbalance severo y la limitación informativa descrita arriba.
- Ninguno de los dos modelos de sentimiento detecta sarcasmo de forma confiable. Para un sistema en producción se necesitaría un modelo entrenado específicamente para estos casos.

6. Recomendaciones

- Para continuar el análisis de accidentalidad: Sería bueno obtener otras variables más representativas como el estado del conductor y la velocidad del vehículo. Esto podría mejorar significativamente la capacidad predictiva del modelo de gravedad.
- Para el análisis de sentimiento en producción: usar Hugging Face (robertuito) como modelo principal y TF-IDF como respaldo rápido cuando no haya GPU disponible. Agregar un módulo específico para detección de sarcasmo si el corpus tiene muchas reseñas con ironía.